IPSSI

2e année Bachelor Informatique

Mathématiques appliquées à l'Intelligence Artificielle

Fiche d'exercices

Jour 1 — Données et représentation mathématique

Auteur : Mohamed EL AFRIT

www.mohamedelafrit.com

Année académique : 2025–2026

© 2025 Mohamed EL AFRIT — IPSSI

Ce contenu est distribué sous licence

Creative Commons BY-NC-SA 4.0

https://creativecommons.org/licenses/by-nc-sa/4.0/deed.fr

Rappel — Dataset fil rouge

Tous les exercices utilisent le dataset **Salaire développeur** (30 observations, 5 features). Colonnes : `experience` (0–20), `nb_langages` (1–8), `niveau_etudes` (1–5), `taille_entreprise` (15–5000), `remote` (0–100), `salaire` (25–72 k€).

#	Exp	Lang	Études	Entrep.	Remote	Salaire
0	0	2	3	150	80	28.0
1	1	1	2	50	100	26.5
2	1	3	4	800	40	35.0
3	2	2	3	200	60	32.0
4	2	4	4	3000	20	38.0
5	0	1	1	30	50	25.0

Régression simple (expérience → salaire) : $\hat{y} = 2{,}07 \times \texttt{experience} + 31{,}27$ (MSE = 20,46).

Exercices crayon-papier — Niveau fondamental

Exercice 1 — ★☆☆ Fondamental — Vecteurs et dimensions

a) Écrivez le vecteur de features $\mathbf{x}_0$ du développeur #0 du dataset. Quelle est sa dimension p ?

b) Écrivez le vecteur $\mathbf{x}_4$ du développeur #4. Écrivez sa transposée $\mathbf{x}_4^T$.

c) Un nouveau développeur a le profil suivant : 6 ans d'expérience, 4 langages, Bac+5, entreprise de 1200 employés, 50% de remote. Écrivez son vecteur $\mathbf{x}$ et précisez $\mathbf{x} \in \mathbb{R}^?$.

d) Peut-on calculer $\mathbf{x}_0 + \mathbf{x}_4$? Et $\mathbf{x}_0 + \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$? Justifiez.

Exercice 2 — ★☆☆ Fondamental — Produit scalaire à la main

a) Calculez le produit scalaire $\langle \mathbf{x}, \mathbf{w} \rangle$ avec :

$$\mathbf{x} = \begin{pmatrix} 3 \\ 5 \\ 2 \end{pmatrix} \qquad \mathbf{w} = \begin{pmatrix} 0.5 \\ 0.3 \\ 0.8 \end{pmatrix}$$

Détaillez le calcul terme à terme.

b) Calculez $\langle \mathbf{x}_0, \mathbf{w} \rangle$ en utilisant le développeur #0 du dataset et le vecteur de poids $\mathbf{w} = \begin{pmatrix} 2.0 \\ 1.5 \\ 3.0 \\ 0.005 \\ 0.02 \end{pmatrix}$. Ajoutez un biais $b = 15$ pour obtenir la prédiction $\hat{y}_0$. Comparez avec le vrai salaire $y_0 = 28{,}0$ k€.

c) **Piège :** peut-on calculer le produit scalaire suivant ?

$$\left\langle \begin{pmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{pmatrix}, \begin{pmatrix} 0.1 \\ 0.2 \\ 0.3 \end{pmatrix} \right\rangle$$

Expliquez pourquoi.

Exercice 3 — ★☆☆ **Fondamental** — Multiplication matrice-vecteur

Soit la matrice $\mathbf{X}$ et le vecteur $\mathbf{w}$ suivants :

$$\mathbf{X} = \begin{pmatrix} 1 & 3 \\ 4 & 2 \\ 0 & 5 \end{pmatrix} \qquad \mathbf{w} = \begin{pmatrix} 2 \\ 0.5 \end{pmatrix}$$

a) Quelle est la dimension de $\mathbf{X}$? De $\mathbf{w}$? Quelle sera la dimension du résultat $\hat{\mathbf{y}} = \mathbf{X}\mathbf{w}$?

b) Calculez $\hat{\mathbf{y}} = \mathbf{X}\mathbf{w}$ en détaillant chaque produit scalaire (ligne par ligne).

c) Vérifiez que $\hat{y}_1 = \mathbf{x}_1^T \mathbf{w}$ où $\mathbf{x}_1^T$ est la première ligne de $\mathbf{X}$.

Exercice 4 — ★☆☆ **Fondamental** — Calcul du MSE

Un modèle a produit les prédictions suivantes pour 5 développeurs :

Développeur i	Salaire réel y_i (k€)	Prédiction $\hat{y}_i$ (k€)
1	28.0	31.3
2	35.0	33.3
3	38.0	35.4
4	44.0	41.6
5	52.0	49.9

a) Calculez l'erreur (résidu) $e_i = y_i - \hat{y}_i$ pour chaque observation.

b) Calculez l'erreur au carré e_i^2 pour chaque observation.

c) Calculez le MSE : $\text{MSE} = \frac{1}{n}\sum_{i=1}^{n} e_i^2$.

d) L'erreur typique du modèle est $\sqrt{\text{MSE}}$. Calculez-la et interprétez : est-ce que le modèle prédit bien ?

Exercices crayon-papier — Niveau intermédiaire

Exercice 5 — ★★☆ **Intermédiaire** — Interpréter les poids d'un modèle

On considère le modèle linéaire suivant pour prédire le salaire (en k€) :

$$\hat{y} = 25 + 3 \times \texttt{experience} + 1{,}5 \times \texttt{nb_langages}$$

a) Identifiez w_0 (biais), w_1 et w_2. Que représente concrètement chacun de ces paramètres ?

b) Quel salaire ce modèle prédit-il pour un développeur avec 0 année d'expérience et 1 langage ? Est-ce réaliste ?
c) Quel est l'impact d'une année d'expérience supplémentaire sur le salaire prédit ? D'un langage supplémentaire ?
d) Si un développeur a 5 ans d'expérience et maîtrise 4 langages, quel salaire le modèle prédit-il ? Comparez avec le développeur #9 du dataset ($y_9 = 44{,}0$ k€).

Exercice 6 — ★★☆ **Intermédiaire** — Choisir le meilleur modèle

Deux modèles concurrents prédisent le salaire à partir de l'expérience seule :

Modèle A :	$\hat{y} = 2{,}0 \times \texttt{experience} + 32$
Modèle B :	$\hat{y} = 3{,}0 \times \texttt{experience} + 25$

Utilisez les 6 premiers développeurs du dataset (voir tableau en haut de page).

a) Calculez les prédictions $\hat{y}_i$ du modèle A pour chaque développeur.
b) Calculez les prédictions $\hat{y}_i$ du modèle B pour chaque développeur.
c) Calculez le MSE du modèle A et le MSE du modèle B.
d) Quel modèle est le meilleur selon le MSE ? Le résultat vous surprend-il ?

Exercice 7 — ★★☆ **Intermédiaire** — Construire la matrice à partir de données textuelles

Voici les profils de 4 développeurs :

— **Alice** : 3 ans d'expérience, 2 langages, Bac+3, PME (150 employés), 80% remote, salaire 34 k€.
— **Bob** : 7 ans, 5 langages, Bac+5, scale-up (800 employés), 50% remote, salaire 50 k€.
— **Clara** : 0 an, 1 langage, Bac, micro-entreprise (20 employés), 100% remote, salaire 24 k€.
— **David** : 12 ans, 6 langages, Bac+5, grand groupe (3000 employés), 30% remote, salaire 58 k€.

a) Construisez la matrice de features $\mathbf{X} \in \mathbb{R}^{?\times ?}$. Précisez les dimensions.
b) Construisez le vecteur cible $\mathbf{y} \in \mathbb{R}^{?}$.
c) Que vaut l'élément $x_{2,4}$? Que représente-t-il concrètement ?
d) En utilisant $\mathbf{w} = \begin{pmatrix} 2 \\ 1.5 \\ 3 \\ 0.005 \\ 0.02 \end{pmatrix}$ et $b = 15$, calculez la prédiction pour Bob ($\hat{y}_2 = \mathbf{w}^T\mathbf{x}_2 + b$).

Exercices Python guidés — Niveau intermédiaire

Exercice 8 — ★★☆ **Intermédiaire** — Créer et manipuler des vecteurs NumPy [Python guidé]

Complétez le code suivant dans Google Colab :

» Squelette -- Vecteurs NumPy

```python
import numpy as np

# 1. Creer le vecteur du developpeur #3 du dataset
x3 = np.array([______])  # A COMPLETER

# 2. Afficher la dimension
print(f"Dimension de x3 : {______}")  # A COMPLETER

# 3. Acceder a la 3e composante (niveau d'etudes)
niveau = ______  # A COMPLETER
print(f"Niveau d'etudes : {niveau}")

# 4. Calculer la norme du vecteur
# Rappel : ||x|| = sqrt(x1**2 + x2**2 + ... + xp**2)
norme = np.sqrt(np.______(x3 ** 2))  # A COMPLETER
print(f"Norme de x3 : {norme:.2f}")

# 5. Creer le vecteur du developpeur #5
x5 = np.array([______])  # A COMPLETER

# 6. Calculer le produit scalaire de x3 et x5
ps = ______  # A COMPLETER (utiliser @)
print(f"Produit scalaire x3 . x5 = {ps}")

# 7. Calculer la distance entre les deux developpeurs
# distance = ||x3 - x5||
distance = np.sqrt(np.sum((______ - ______) ** 2))
print(f"Distance : {distance:.2f}")
```

Exercice 9 — ★★☆ **Intermédiaire** — Construire la matrice du dataset [Python guidé]

» Squelette -- Matrice NumPy

```python
import numpy as np

# 1. Creer la matrice des 6 premiers developpeurs
#    (5 features seulement, pas le salaire)
X = np.array([
    [0, 2, 3, 150, 80],
    [1, 1, 2, 50, 100],
    ______,  # A COMPLETER : dev #2
    ______,  # A COMPLETER : dev #3
    ______,  # A COMPLETER : dev #4
    ______,  # A COMPLETER : dev #5
])

# 2. Verifier les dimensions
print(f"Shape de X : {______}")  # doit afficher (6, 5)
```

```python

# 3. Extraire la colonne "experience" (colonne 0)
experience = X[:, ______]  # A COMPLETER
print(f"Experiences : {experience}")

# 4. Extraire la ligne du developpeur #4
dev4 = X[______, :]  # A COMPLETER
print(f"Developpeur #4 : {dev4}")

# 5. Creer le vecteur des salaires
y = np.array([28.0, 26.5, ______, ______, ______, ______])

# 6. Calculer la transposee et afficher son shape
print(f"Shape de X.T : {______}")  # doit afficher (5, 6)

# 7. Quelle est la valeur de X[2, 3] ?
#    Que represente-t-elle ?
print(f"X[2,3] = {X[2, 3]}")  # interpreter !
```

Exercice 10 — ★★☆ **Intermédiaire** — Régression linéaire from scratch [Python guidé]

» Squelette -- Régression linéaire

```python
import numpy as np
import matplotlib.pyplot as plt

# Donnees completes (experience, salaire)
experience = np.array([0,1,1,2,2,0,3,1,4,5,5,6,6,7,7,4,
                       8,5,9,10,10,11,12,9,13,11,15,17,20,18])
salaire = np.array([28.0,26.5,35.0,32.0,38.0,25.0,34.5,42.0,
    38.5,44.0,41.0,48.0,43.5,50.0,39.0,47.0,51.0,40.0,
    52.0,55.0,48.5,58.0,60.0,42.0,62.0,54.0,65.0,68.0,72.0,58.0])

# 1. Calculer les moyennes
x_mean = ______  # A COMPLETER
y_mean = ______  # A COMPLETER

# 2. Calculer la pente w (formule des moindres carres)
# w = sum((xi - x_mean) * (yi - y_mean)) / sum((xi - x_mean)**2)
numerateur = np.sum(______)    # A COMPLETER
denominateur = np.sum(______)  # A COMPLETER
w = numerateur / denominateur
print(f"Pente w = {w:.4f}")

# 3. Calculer le biais b
b = ______  # A COMPLETER (formule : y_mean - w * x_mean)
print(f"Biais b = {b:.4f}")

# 4. Calculer les predictions pour tous les developpeurs
y_pred = ______  # A COMPLETER (formule : w * experience + b)
```

```python

# 5. Calculer le MSE
mse = np.mean(______)  # A COMPLETER
print(f"MSE = {mse:.2f}")

# 6. Tracer le graphique
fig, ax = plt.subplots(figsize=(8, 5))
ax.scatter(experience, salaire, c='blue', label='Donnees')
x_line = np.linspace(0, 21, 100)
ax.plot(x_line, ______, 'r--', label=f'y={w:.2f}x+{b:.2f}')
ax.set_xlabel("Experience (annees)")
ax.set_ylabel("Salaire (kEUR)")
ax.set_title("Regression lineaire from scratch")
ax.legend()
ax.grid(True, alpha=0.3)
plt.show()
```

Exercices Python autonomes — Niveau avancé

Exercice 11 — ★★★ **Avancé** — Explorer le dataset salaire [Python autonome]

Écrivez un programme Python complet (sans squelette) qui réalise les tâches suivantes à partir du dataset fil rouge (30 développeurs, 6 colonnes) :

a) Chargez le dataset complet dans un tableau NumPy. Affichez ses dimensions et les 5 premières lignes.

b) Calculez et affichez pour chaque colonne : la **moyenne**, l'**écart-type**, le **minimum** et le **maximum**.

c) Calculez la **corrélation** entre chaque feature et le salaire. *Rappel :* $r_{xy} = \frac{\sum(x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\sum(x_i-\bar{x})^2 \cdot \sum(y_i-\bar{y})^2}}$ (ou utilisez `np.corrcoef`).

d) Tracez un graphique avec 5 sous-figures (une par feature) montrant chaque feature en abscisse et le salaire en ordonnée. Quelle feature semble la plus corrélée au salaire visuellement ?

Consignes

- Utilisez **uniquement** NumPy et Matplotlib (pas de pandas).
- Commentez votre code en français.
- Affichez des résultats lisibles avec `f-strings` formatées.

Exercice 12 — ★★★ **Avancé** — Tester plusieurs modèles [Python autonome]

Vous êtes data scientist junior. Votre manager vous demande de comparer 3 modèles linéaires simples (expérience → salaire) :

Modèle	Formule	w_1	w_0
A	$\hat{y} = 1{,}5 \times x + 33$	1.5	33
B	$\hat{y} = 2{,}07 \times x + 31{,}27$	2.07	31.27
C	$\hat{y} = 2{,}8 \times x + 28$	2.8	28

Écrivez un programme Python complet qui :

a) Charge le dataset et extrait les colonnes `experience` et `salaire`.
b) Pour chacun des 3 modèles, calcule les prédictions $\hat{\mathbf{y}}$ et le MSE associé. Affichez un tableau récapitulatif.
c) Trace un **unique graphique** montrant :
   — les 30 points du dataset (nuage de points),
   — les 3 droites de régression (avec une couleur et un label différents),
   — une légende indiquant le MSE de chaque modèle.
d) Répondez (en commentaire ou `print`) : quel modèle est le meilleur ? Pourquoi était-ce prévisible ?

Indice

Le modèle B correspond à la droite des moindres carrés calculée en cours. Est-ce forcément le meilleur ?

Répartition : 4 exercices ★ fondamentaux 3 exercices ★★ intermédiaires 3 guidés Python ★★ 2 autonomes ★★★

© 2025 Mohamed EL AFRIT — IPSSI • www.mohamedelafrit.com • CC BY-NC-SA 4.0