IPSSI

2e année Bachelor Informatique

Mathématiques appliquées à l'Intelligence Artificielle

Fiche de synthèse

Jour 1 — Données et représentation mathématique

Auteur : Mohamed EL AFRIT

www.mohamedelafrit.com

Année académique : 2025–2026

© 2025 Mohamed EL AFRIT — IPSSI

Ce contenu est distribué sous licence

Creative Commons BY-NC-SA 4.0

https://creativecommons.org/licenses/by-nc-sa/4.0/deed.fr

1 L'IA comme fonction mathématique

Un modèle d'intelligence artificielle est une **fonction mathématique** qui transforme des entrées numériques en une sortie (la prédiction).

Fonction de prédiction

Une **fonction de prédiction** $f_{\boldsymbol{\theta}} : \mathbb{R}^p \to \mathbb{R}$ associe à un vecteur d'entrée $\mathbf{x}$ composé de p features une valeur $\hat{y}$:

$$\boxed{\hat{y} = f_{\boldsymbol{\theta}}(\mathbf{x})}$$

- $\mathbf{x} \in \mathbb{R}^p$: vecteur d'entrée (les *features* de l'observation)
- $\boldsymbol{\theta}$: **paramètres** du modèle (poids et biais)
- $\hat{y}$: **prédiction** (valeur estimée par le modèle)

Dans le cas **linéaire**, la fonction prend la forme :

$$\boxed{\hat{y} = \mathbf{w}^T\mathbf{x} + b}$$

où $\mathbf{w} \in \mathbb{R}^p$ est le vecteur de **poids** (weights) et $b \in \mathbb{R}$ le **biais** (bias).

Apprendre = ajuster les paramètres

L'**apprentissage** consiste à trouver les valeurs de $\boldsymbol{\theta} = (\mathbf{w}, b)$ qui minimisent l'écart entre les prédictions $\hat{y}$ et les vraies valeurs y.

2 Vecteurs et matrices

2.1 Vecteur de caractéristiques

Vecteur (feature vector)

Un **vecteur de caractéristiques** représente une observation par p valeurs numériques :

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{pmatrix} \in \mathbb{R}^p$$

Chaque composante x_j correspond à une feature. La **transposée** $\mathbf{x}^T = (x_1\ x_2\ \cdots\ x_p)$ est la version en ligne.

Développeur #2 du dataset

$p = 5$ features $\to \mathbf{x}_2 = \begin{pmatrix} 1 & 3 & 4 & 800 & 40 \end{pmatrix}^T$ avec salaire réel $y_2 = 35{,}0$ k€.

2.2 Matrice de données

Matrice de données

La **matrice de données** $\mathbf{X} \in \mathbb{R}^{n \times p}$ regroupe n observations de p features. Chaque **ligne** i = une observation $\mathbf{x}_i^T$, chaque **colonne** j = une feature. L'élément x_{ij} = valeur de la feature j pour l'observation i. *Notre dataset :* $\mathbf{X} \in \mathbb{R}^{30 \times 5}$.

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

2.3 Conventions de notation

Objet	Notation	Convention
Scalaire	n, p, α	minuscule italique
Vecteur	$\mathbf{x}, \mathbf{w}$	minuscule **gras**
Matrice	$\mathbf{X}, \mathbf{W}$	majuscule **gras**
Prédiction	$\hat{y}$	accent *chapeau*
Transposée	$\mathbf{x}^T, \mathbf{X}^T$	exposant T
Composante	x_i, x_{ij}	indice(s)

Dimension

On ne peut additionner que des vecteurs de **même dimension**. En NumPy, la propriété `shape` indique toujours la dimension d'un tableau.

3 Produit scalaire

Produit scalaire

Le produit scalaire de $\mathbf{x}, \mathbf{w} \in \mathbb{R}^p$ admet trois écritures équivalentes :

$$\langle \mathbf{x}, \mathbf{w} \rangle \;=\; \mathbf{x}^T \mathbf{w} \;=\; \sum_{i=1}^{p} x_i \, w_i$$

Le résultat est un **scalaire** (un seul nombre).

Propriétés essentielles :

1. **Commutativité :** $\langle \mathbf{x}, \mathbf{w} \rangle = \langle \mathbf{w}, \mathbf{x} \rangle$
2. **Linéarité :** $\langle \mathbf{x}, \alpha \mathbf{w} + \beta \mathbf{v} \rangle = \alpha \langle \mathbf{x}, \mathbf{w} \rangle + \beta \langle \mathbf{x}, \mathbf{v} \rangle$
3. **Positivité :** $\langle \mathbf{x}, \mathbf{x} \rangle = \|\mathbf{x}\|^2 \geq 0$ (lié à la norme du vecteur)

Lien avec la prédiction

Toute prédiction linéaire est un produit scalaire : $\hat{y} = \langle \mathbf{x}, \mathbf{w} \rangle + b = \underbrace{x_1 w_1}_{\text{exp.}} + \underbrace{x_2 w_2}_{\text{lang.}} + \cdots +$

$\underbrace{x_p w_p}_{\text{remote}} + b$. Chaque poids w_j mesure l'**importance** de la feature j.

Multiplication matrice-vecteur. Pour prédire le salaire de *tous* les développeurs d'un coup :

$$\hat{\mathbf{y}} = \mathbf{X}\mathbf{w} \in \mathbb{R}^n$$

Chaque composante $\hat{y}_i = \mathbf{x}_i^T \mathbf{w}$ est un produit scalaire. C'est n **produits scalaires en parallèle**.

4 Régression linéaire

Le modèle de régression linéaire prédit une valeur continue : **cas simple** $\hat{y} = w_1 x + w_0$; **cas général** $\hat{y} = \mathbf{w}^T \mathbf{x} + b$; **forme matricielle** $\hat{\mathbf{y}} = \mathbf{X}\mathbf{w} + b\,\mathbf{1}_n$.

Sur notre dataset (expérience → salaire) :

$$\hat{y} = 2{,}07 \times \texttt{experience} + 31{,}27$$

Interprétation : +1 an d'expérience ≈ +2,07 k€ de salaire prédit ; salaire de base estimé à 31,27 k€.

Erreur quadratique moyenne — MSE

Le **MSE** (*Mean Squared Error*) mesure la qualité du modèle :

$$\text{MSE} = J(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 \tag{1}$$

On élève au carré pour pénaliser les grosses erreurs et éviter les compensations entre erreurs positives et négatives.

Objectif de l'apprentissage

Trouver $\mathbf{w}$ qui **minimise** $J(\mathbf{w})$. La **descente de gradient** (Jour 2) automatisera cette recherche. Sur notre dataset : MSE = 20,46 (k€)^2 ⇒ erreur typique ≈ 4,5 k€.

5 Synthèse et formules essentielles

5.1 Tableau récapitulatif

Concept	Notation	Code NumPy
Observation (vecteur)	$\mathbf{x} \in \mathbb{R}^p$	`x = np.array([1, 3, 4, 800, 40])`
Dataset (matrice)	$\mathbf{X} \in \mathbb{R}^{n \times p}$	`X = np.array([[...], ...])`
Transposée	$\mathbf{X}^T$	`X.T`
Produit scalaire	$\langle \mathbf{x}, \mathbf{w} \rangle = \mathbf{x}^T \mathbf{w}$	`np.dot(x, w)` ou `x @ w`
Prédiction	$\hat{y} = \mathbf{w}^T \mathbf{x} + b$	`x @ w + b`
Toutes les prédictions	$\hat{\mathbf{y}} = \mathbf{X}\mathbf{w}$	`X @ w`
Erreur MSE	$\frac{1}{n} \sum (y_i - \hat{y}_i)^2$	`np.mean((y - y_pred)**2)`
Pente (rég. simple)	w_1	formule analytique (éq. 6)
Biais	w_0 ou b	`y.mean() - w * x.mean()`

5.2 Formules à retenir

Formules du Jour 1

$$\text{Produit scalaire} \quad \langle \mathbf{x}, \mathbf{w} \rangle = \sum_{i=1}^{p} x_i \, w_i \tag{2}$$

$$\text{Prédiction linéaire} \quad \hat{y} = \mathbf{w}^T \mathbf{x} + b \tag{3}$$

$$\text{Prédictions matricielles} \quad \hat{\mathbf{y}} = \mathbf{X}\mathbf{w} + b\,\mathbf{1}_n \tag{4}$$

$$\text{Erreur quadratique} \quad J(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 \tag{5}$$

$$\text{Pente (rég. simple)} \quad w_1 = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2} \tag{6}$$

$$\text{Ordonnée à l'origine} \quad w_0 = \bar{y} - w_1 \, \bar{x} \tag{7}$$

Pipeline du Jour 1 : Données $\longrightarrow$ Vecteur $\mathbf{x}$ $\longrightarrow$ Matrice $\mathbf{X}$ $\longrightarrow$ Produit $\mathbf{X}\mathbf{w}$ $\longrightarrow$ Prédiction $\hat{y}$

© 2025 Mohamed EL AFRIT — IPSSI • www.mohamedelafrit.com • CC BY-NC-SA 4.0