IPSSI

2e année Bachelor Informatique

Mathématiques appliquées à l'Intelligence Artificielle

Fiche de synthèse

Jour 3 — Probabilités et classification

Auteur : Mohamed EL AFRIT

www.mohamedelafrit.com

Année académique : 2025–2026

© 2025 Mohamed EL AFRIT — IPSSI

Ce contenu est distribué sous licence

Creative Commons BY-NC-SA 4.0

https://creativecommons.org/licenses/by-nc-sa/4.0/deed.fr

1 De la régression à la classification

Au lieu de prédire un salaire exact (régression), on prédit une **catégorie** : le développeur gagne-t-il plus ou moins de 45 k€ ?

Classification binaire

Un problème de **classification binaire** consiste à prédire une variable cible $y \in \{0, 1\}$ à partir de features $\mathbf{x}$:

$$f : \mathbb{R}^p \longrightarrow \{0, 1\}$$

- $y = 0$: classe négative (salaire $\leq$ 45 k€)
- $y = 1$: classe positive (salaire $>$ 45 k€)

Notre dataset est **équilibré** : 15 développeurs dans chaque classe.

2 Rappels de probabilités utiles

Probabilité

La probabilité d'un événement A est un nombre $P(A) \in [0, 1]$. On l'**estime** à partir des données : $P(A) \approx \frac{\text{nombre de cas favorables}}{\text{nombre total}}$.

Exemple : $P(\text{salaire_eleve} = 1) = \frac{15}{30} = 0{,}5$.

Probabilité conditionnelle

La probabilité de A **sachant** B :

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} \tag{1}$$

Exemple : $P(\text{sal}{>}45\text{k} \mid \text{exp}{>}5) \approx 0{,}85$ vs. $P(\text{sal}{>}45\text{k} \mid \text{exp}{\leq}5) \approx 0{,}17$.

Notion	Formule	Intuition
Probabilité	$P(A) \in [0, 1]$	Fréquence relative d'un événement
Espérance	$E[Y] = \sum_k k \cdot P(Y{=}k)$	Moyenne théorique
Variance	$\text{Var}(Y) = E[(Y{-}E[Y])^2]$	Dispersion autour de la moyenne
Var. binaire	$\text{Var}(Y) = p(1{-}p)$	Max. quand $p = 0{,}5$

3 Classification linéaire et frontière de décision

Classifieur linéaire

Un classifieur linéaire utilise une **fonction de décision** :

$$g(\mathbf{x}) = \mathbf{w}^T\mathbf{x} + b \tag{2}$$

et la **règle de décision** : $\hat{y} = 1$ si $g(\mathbf{x}) > 0$, $\quad \hat{y} = 0$ sinon.

Frontière de décision (hyperplan)

La **frontière** est l'ensemble des points où $g(\mathbf{x}) = 0$:

$$\mathbf{w}^T\mathbf{x} + b = 0 \tag{3}$$

Avec 2 features : droite $x_2 = -\frac{w_1}{w_2}\,x_1 - \frac{b}{w_2}$.

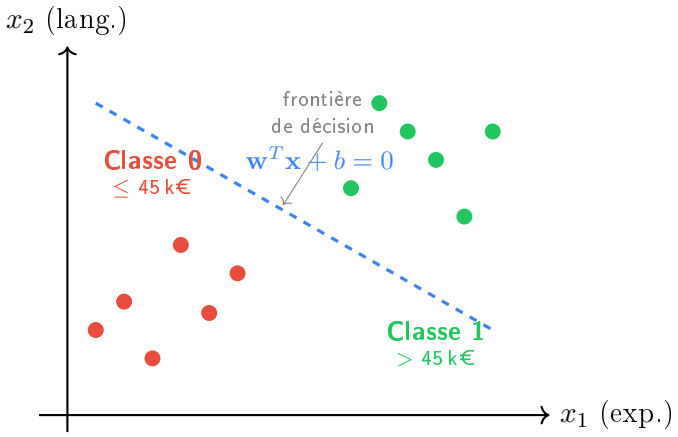

À retenir

La classification linéaire = régression (produit scalaire + biais) + on regarde le **signe**. D'un côté de la frontière : classe 0, de l'autre : classe 1.

4 Le perceptron

Le **perceptron** (Rosenblatt, 1957) est le premier neurone artificiel.

Modèle du perceptron

$$\hat{y} = \text{signe}(\mathbf{w}^T\mathbf{x} + b) \quad \text{avec} \quad \text{signe}(z) = \begin{cases} 1 & \text{si } z > 0 \\ 0 & \text{sinon} \end{cases} \tag{4}$$

Algorithme d'apprentissage

Pour chaque observation $(\mathbf{x}_i, y_i)$:

1. **Prédire** : $\hat{y}_i = \text{signe}(\mathbf{w}^T\mathbf{x}_i + b)$
2. **Si erreur** $(\hat{y}_i \neq y_i)$, **mettre à jour** :

$$\mathbf{w} \leftarrow \mathbf{w} + \alpha \cdot (y_i - \hat{y}_i) \cdot \mathbf{x}_i \tag{5}$$

$$b \leftarrow b + \alpha \cdot (y_i - \hat{y}_i) \tag{6}$$

Répéter sur tout le dataset, plusieurs fois (époques).

Fonctionnement

Si le perceptron prédit **0 alors que la vraie classe est 1** ($y_i - \hat{y}_i = +1$) : les poids sont **augmentés** dans la direction de $\mathbf{x}_i$, poussant la frontière pour inclure ce point dans la zone "classe 1".
S'il prédit **1 au lieu de 0** ($y_i - \hat{y}_i = -1$) : les poids sont **diminués**, repoussant la frontière.
S'il ne se trompe pas : aucun changement.

Résultat sur le dataset salaire

Avec 2 features (expérience, nb_langages), $\alpha = 0{,}1$, 100 époques :

Accuracy $\approx$ **87–93%** (selon l'initialisation).
Le perceptron sépare correctement la majorité des développeurs, mais quelques cas atypiques (junior bien payé, senior sous-payé) restent mal classés.

5 Limites du perceptron — Le problème XOR

Limite fondamentale

Le perceptron ne résout que les problèmes **linéairement séparables** — où une droite (ou un hyperplan) suffit à séparer les classes.

Le **XOR** (ou exclusif) n'est *pas* linéairement séparable : les points $(0,0)$ et $(1,1)$ sont en classe 0, les points $(0,1)$ et $(1,0)$ en classe 1. Aucune droite ne peut les séparer.

$\Rightarrow$ Il faut **plus d'un neurone** : c'est l'idée des **réseaux de neurones multicouches** (Jour 4).

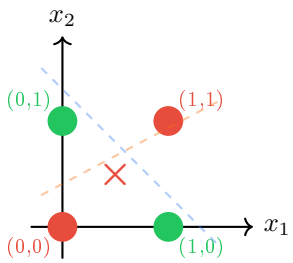

Aucune droite ne sépare les classes

6 Tableau comparatif : régression vs classification

	Régression (Jours 1–2)	**Classification (Jour 3)**
Question	Combien ?	Quelle classe ?
Sortie y	Nombre réel (salaire)	Étiquette $\{0, 1\}$
Modèle	$\hat{y} = \mathbf{w}^T\mathbf{x} + b$	$\hat{y} = \text{signe}(\mathbf{w}^T\mathbf{x} + b)$
Mesure d'erreur	MSE : $\frac{1}{n}\sum(y_i - \hat{y}_i)^2$	Accuracy : % bien classés
Optimisation	Descente de gradient	Correction d'erreurs
Frontière	Droite de régression	Hyperplan de décision
scikit-learn	`LinearRegression`	`Perceptron`

7 Formules essentielles à retenir

Formules du Jour 3

$$\text{Probabilité conditionnelle} \quad P(A \mid B) = \frac{P(A \cap B)}{P(B)} \tag{7}$$

$$\text{Fonction de décision} \quad g(\mathbf{x}) = \mathbf{w}^T\mathbf{x} + b \tag{8}$$

$$\text{Frontière} \quad \mathbf{w}^T\mathbf{x} + b = 0 \tag{9}$$

$$\text{Perceptron} \quad \hat{y} = \text{signe}(\mathbf{w}^T\mathbf{x} + b) \tag{10}$$

$$\text{Mise à jour poids} \quad \mathbf{w} \leftarrow \mathbf{w} + \alpha\,(y_i - \hat{y}_i)\,\mathbf{x}_i \tag{11}$$

$$\text{Mise à jour biais} \quad b \leftarrow b + \alpha\,(y_i - \hat{y}_i) \tag{12}$$

Pipeline du Jour 3 : Features $\mathbf{x}$ $\longrightarrow$ Score $\mathbf{w}^T\mathbf{x} + b$ $\longrightarrow$ Signe $\longrightarrow$ Classe $\hat{y} \in \{0, 1\}$

© 2025 Mohamed EL AFRIT — IPSSI • www.mohamedelafrit.com • CC BY-NC-SA 4.0